

vLLM 0.13.0 + PyTorch 2.5.1 部署指南

H20 sm_90 32,955 2026-08-22

H20 上 vllm 0.13.0 + torch 2.5.1+cu124 部署 vLLM 部署指南

部署环境——vllm 0.13.0 + torch 2.5.1 部署 torch

部署 runs/ut-20260808-manifest-remaining/manifest.json 8/8 32,955

部署 v0.13.0_torch2.5.1_compile python3.12 · torch 2.5.1+cu124 · triton 3.5.0

26,875
passed (81.5%)

3,095
failed (9.4%)

810
error (2.5%)

2,170
ignored (6.6%)

2,122
部署

0. 部署

部署	passed	部署
8/9 部署 ut-20260807-110322	6,019	部署 failed 3,006 / error 904 / ignored 2,106 / retrieable 3
8/8 部署 ut-20260808-manifest-remaining部署	6,080	failed 3,095 / error 810 / ignored 2,170 / retrieable 5
dataset 8/20 部署	4,456 + 1,624 pending	1,624 部署 pending

部署 61 部署 8/8 → 8/9 部署 157 部署 error → failed 68 部署 passed → ignored 40 部署 error → ignored 24 部署 passed → failed 21 部署 passed +61 部署 8/8 部署 部署

1. 部署部署

1.1 部署

部署	部署	部署 (passed)	部署
A. 部署部署	2,122	34.9%	vllm 0.13.0 部署 torch 2.5.1 / triton 3.5.0 部署部署
B. 部署部署/部署	1,301	21.4%	部署/部署部署
C. timeout 部署 executor 部署	1,787	29.4%	watchdog SIGKILL/JUnit 部署部署
D. 部署部署/部署/executor 部署	870	14.3%	部署 193部署 17部署 5

1.2 部署部署部署A 部署2,122 部署

部署	部署	部署	部署
marlin 部署 部署gptq_marlin_gemm/repack/moe_wna16/marlin_int4_fp8 + opcheck 64	841	部署 CUDA arch 部署 sm52部署marlin 部署 8.0+PTX部署	easy

triton_key 问题	519	vllm 0.13.0 中 triton.compiler.compiler.triton_key 与 triton 3.5.0 不兼容 495 中 triton_key 24 中 LoweringException 在 aten._scaled_mm.default 中	medium
cat_cuda 中 Float8_e4m3fn	225	torch 2.5.1 中 cat_cuda 中 FP8 中 cat	medium
engine 问题	181	error_message 中 See root cause above 中 —— 中	medium
deep_gemm 问题	133	vllm 0.13.0 中 deep_gemm 中 / 中	easy
torch 中 float8_e8m0fnu	80	torch ≥2.7 中 2.5.1 中	difficult
triton 中 / 中	69	Cannot find a working triton installation	easy
flash_attn head_size 中	64	head_size should be a multiple of 16	medium
cuDNN 中	8	CUDNN_STATUS_NOT_INITIALIZED 中 mamba causal_conv1d 中	medium
inductor 中 torch ≥2.9	2	use_inductor_graph_partition 中	easy

1.2.1 marlin 问题

```
1 中 NotImplementedError: Could not run '_C::gptq_marlin_gemm' 479 + _C::gptq_marlin_repack 292 +
   _moe_C::moe_wna16_marlin_gemm 4 + _C::marlin_int4_fp8_preprocess 2 = 777 中 opcheck 64 中 gptq_marlin_repack 36 /
gptq_marlin_24_gemm 16 / awq_marlin_repack 12 中 841 中
2 中 nm -D vllm/_C.abi3.so | grep -ic marlin → 0 中 marlin 中
3 中 CMakeCache.txt 中 CMAKE_CUDA_ARCHITECTURES:STRING=52 中 sm_52 中 marlin 中 MARLIN_ARCHS = 8.0+PTX 中 CUDA_ARCHS → 中
marlin 0 中
4 中 H20 中 nvidia-smi 中 H20 compute_cap = 9.0 中 sm_90 中 marlin 中 → 中
5 中 _moe_C.abi3.so 8/7 中 moe marlin 中 4 中 → 中
  中 arch 中 = TORCH_CUDA_ARCH_LIST="9.0" 中 841 中
```

1.2.2 triton_key 问题

```
1 中 ImportError: cannot import name 'triton_key' from 'triton.compiler.compiler' 495 + 24 中
2 中 from triton.compiler.compiler import triton_key → 中 ImportError
3 中 triton 3.5.0 中 python3.12
  中 triton 中 vllm 0.13.0 中 triton 中 patch 中
```

1.2.3 torch 2.5.1 中 FP8 问题

- cat_cuda not implemented for 'Float8_e4m3fn' 225 中 torch 2.5.1 cat 中 FP8 中 test_batched_moe.py(192)
- module 'torch' has no attribute 'float8_e8m0fnu' 80 中 E8M0 中 torch 2.7+ 中 vllm 0.13.0 中 → 中 vllm 0.13.0 中 torch 2.5.1
- 中 305 中 torch 2.5.1 中 vllm 0.13.0 中 FP8 中 H20 中

1.3 中 B 中 1,301 中 —— 中

中	failed	error	中
HF 中	377	529	906

repo IDValidationError/ValueError	249	7	256
Read/ConnectTimeout	39	47	86
OfflineMode	1	51	52
	1	0	1

TOP deepseek-ai/DeepSeek-R1 (48) · meta-llama/Meta-Llama-3-8B-Instruct (46) · meta-llama/Meta-Llama-3-8B (31) · microsoft/Phi-3.5-vision-instruct (24) · Qwen-VL · GLM-4.1V 29 meta-llama gated repo token

1.4 timeout C 1,787

JUnit XML unparseableSIGKILL mid-flush	1,038	watchdog XML
JUnit XML missing	488	XML
JUnit XML testcase	229	
timeout	32	pytest-timeout

test_detokenize.py (902) · test_attention.py(135) · test_chat_utils.py(41) · test_config.py(38) · test_spec_decode.py(34)executor watchdog bifrost 180s + timeout

detokenize 902 triton/FP8 A — \$4

1.5 D 870

pytest skipped / filtered	246	241 skipped5 filtered
	193	/ —
ignored	120	error_message —
error server	99	Server exited unexpectedlytest_online 17
failed RuntimeError	37	—
failed TypeError	36	—
failed ProcessRaisedException	21	—
	17	hybrid_lb_dp/internal_lb_dp
failed ValueError	15	—
error collection	8	collection
failed HarmonyError	7	vocab
failed WorkerProc	6	worker
failed RuntimeEnvSetupError	5	

error 错误	5	错误
failed KeyError	4	错误 —— 错误
error HarmonyError	3	vocab 错误错误
failed 错误错误	2	错误
failed AttributeError	1	错误
retriable_error	5	错误错误 bug 3 + bifrost 错误 2 —— 错误
failed 错误错误	40	错误错误 —— 错误

Engine core initialization failed 错误 error 错误 61 错误 \$1.2 A 错误 engine 错误错误 181= failed 120 + error 61错误错误错误Harmony vocab 错误 10 错误failed 7 + error 3错误错误

1.6 错误错误错误错误

错误	错误	错误
test_marlin_gemm.py	605	marlin 错误
test_block_fp8.py	384	triton_key 256 + deep_gemm 128
test_moe.py	316	marlin_moe + FP8
test_batched_moe.py	288	cat_cuda Float8 + triton_key
test_grouped_topk.py	96	triton_key
test_flash_attn.py	64	head_size 错误
test_silu_mul_quant_fusion.py	47	triton_key
test_batched_deepgemm.py	32	deep_gemm 错误
test_fusion_attn.py	24	FP8/compile

2. 错误 vllm 错误错误2.5.1_ut_verify 错误30 错误 commit

2.1 错误错误13 错误 commit

Commit	错误	错误	错误
17190b075	06-26	PyTorch 2.5.1 错误 requirements/CMakeLists 错误	错误
d343dc8e0	06-29	错误 compilation/torch_compat.py	错误
bf867df43	06-29	MemPool.snapshot 错误 stub	AttributeError: MemPool snapshot
284316193	06-24	torch._dynamo.config.recompile_limit 错误	torch≥2.6 错误

04cd1dffb	05-28	<code>list[torch.Tensor] → List[torch.Tensor]</code>	<code>infer_schema</code> 🐛
15565df57	05-29	DeepSeek <code>torch_compile</code> <code>dynamic_arg_dims</code> 🐛🐛	<code>compile</code> 🐛
f4f1077c9	07-28	Response API <code>inline_call</code> 🐛 4 🐛 + <code>enforce-eager</code>	<code>InternalTorchDynamoError</code>
73810b8ff / 480f106b1 / 0969c54a1 / 3bf7e2f08 / 755a5000f	06-29~07-02	🐛 <code>meta-llama/Hermes</code> 🐛🐛🐛 + 🐛🐛🐛 + <code>LoRA</code> 🐛🐛🐛	HF <code>gated</code> 🐛
e0b23b56c	08-03	<code>run_collect.sh</code> 🐛🐛🐛🐛	🐛

2.2 🐛🐛🐛🐛🐛17 🐛 `commit`🐛`vllm` 🐛🐛

🐛	<code>Commit</code> 🐛🐛	🐛
Attention	55f1fc1b1 / 30fe765e9 / b2eb84de7	<code>PrefixLM TritonAttention backend</code> / <code>FlexAttention</code> 🐛 <code>max logical block index</code> / <code>mm_prefix</code> 🐛 <code>tile_size=64</code>
Config	72506c983	<code>rope_parameters</code> 🐛 <code>truthy</code> 🐛🐛🐛🐛🐛🐛
DeepEP/DeepGEMM	2c0ee0fde / 17f398809	DeepEP HT + PIECEWISE CG <code>partial revert</code> / <code>profile run workspace</code> 🐛🐛🐛
🐛	761b730dc	<code>workspace</code> 🐛🐛🐛🐛🐛🐛
CPU/ROCm/XPU	d78e128b8 / f34eca5f0 / f124b5678	<code>ROPE dispatch</code> / <code>sdpa</code> / <code>FP8</code> 🐛🐛🐛
🐛	ac43367ce	<code>Jais2</code> 🐛
CI	682c38583 / 4cd332f3c / e397bd659 / 6a88d590b	🐛 <code>flaky</code> / <code>skip</code> 🐛🐛🐛
CustomOp	ad8c07313	<code>ApplyRotaryEmb</code> 🐛🐛 <code>CustomOp</code>
MM	16484d394	<code>encoder cache</code> 🐛

🐛🐛2.2 🐛 `vllm` 🐛🐛🐛🐛🐛 `torch 2.5.1` 🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛

2.3 🐛🐛🐛🐛🐛

🐛	🐛
<code>MemPool.snapshot</code> / <code>recompile_limit</code> / <code>inline_call</code> / <code>list[torch.Tensor]</code> / <code>meta-llama</code> 🐛	🐛 🐛🐛🐛 <code>patch</code> 🐛🐛🐛🐛
<code>marlin</code> 🐛🐛🐛841🐛	🐛 🐛 ——— <code>marlin</code> 🐛 <code>arch</code> 🐛🐛🐛
<code>triton_key</code> 🐛519🐛	🐛 🐛 ——— <code>triton</code> 🐛🐛🐛
<code>cat_cuda Float8</code> 🐛225🐛/ <code>float8_e8m0fnu</code> 🐛80🐛	🐛 🐛 ——— <code>torch 2.5.1</code> 🐛🐛🐛

🐛🐛🐛🐛🐛🐛 `torch API` 🐛🐛🐛B 🐛🐛🐛🐛🐛 🐛🐛🐛🐛`marlin/triton/FP8`🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛🐛 ——— 🐛🐛🐛🐛🐛🐛🐛🐛

3. 🐛🐛🐛🐛🐛🐛🐛🐛🐛

- 1. arch C.abi3.so sm52 marlin torch 841
- 2. triton triton 3.5.0 vllm 0.13.0
- 3. HF 29 B 1,301 906 + repo 256 + 138 + 1 gated model_replacement.py
- 4. executor timeout 1,787 detokenize 902vs executor
- 5. 17 —
- 6. retrieable_error bug3 bash -c — apmm
- 7. GPU1 Xid31 exclude_gpus=[1] 8 cuDNN

4.

	193	vs vllm bug vs FP8
failed	40	error_message
failed RuntimeError	37	
failed TypeError	36	
failed ProcessRaisedException	21	
ignored	120	error_message
failed ValueError	15	
failed KeyError / / AttributeError	7	
detokenize timeout	~200-300	
engine init	~50	
	~720-820	469 + ~250-350 passed 12-13%

5.

26,875/32,955 = 81.5% passed 6,080 2,12234.9%marlin arch + triton + torch 2.5.1 FP8

easy 1,04549.2%= marlin 841 + deep_gemm 133 + triton 69 + inductor 2medium 99747.0%= triton_key 519 + cat_cuda 225 + engine 181 + head_size 64 + cuDNN 8difficult 803.8%= float8_e8m0fnu 1,301 timeout 1,787

torch —

torch 2.6+/2.7+ vllm 0.13.0 torch 2.7+ APIfloat8_e8m0fnu 80 torch 2.5.1 FP8 cat_cuda 225 FP8 H20

vllm main torch 2.11.0 2026-04-26 2.5.1 triton

marlin 841 2 1,301 + timeout 1,787 + 5 3,093 torch 3 2.5.1

📋 更新履歴

更新	内容	差分
P0	🔧 TORCH_CUDA_ARCH_LIST="9.0" を追加 vllm を marlin に	+841
P0	🔧 vllm 0.13.0 を triton に patch triton_key を	+519
P1	🔧 HF gated を追加	+1,301
P1	🔧 executor timeout を追加	+1,787
P2	🔧 torch 2.6/2.7 の FP8 cat_cuda/float8_e8m0fnu を	+305
P2	🔧 ~720-820 のパッチ/バグ/改善	

📌 備考

vllm 0.13.0 + torch 2.5.1 の H20 のパフォーマンスは 1/3 程度、torch 2.5.1 の FP8 の API は 2.7 の FP8 と torch 2.6+ の vllm の marlin と

📄 runs/ut-20260808-manifest-remaining/manifest.json 32,955 行 - ut_logs.db の error_message を + 追加/削除 easy=簡単・medium=🔧 patch/バグ・difficult=🔧 summary/non-passed 2026-08-22