

vLLM 0.13.0 + PyTorch 2.5.1 部署指南

H20 8000 32,955 2026-08-22

H20 上 vllm 0.13.0 + torch 2.5.1+cu124 部署 vLLM 部署指南

部署环境——vllm 0.13.0 + torch 2.5.1 部署 torch

部署 runs/ut-20260808-manifest-remaining/manifest.json 8/8 部署 32,955

部署 v0.13.0_torch2.5.1_compile python3.12 · torch 2.5.1+cu124 · triton 3.5.0

26,875
passed (81.5%)

3,095
failed (9.4%)

810
error (2.5%)

2,170
ignored (6.6%)

2,122
部署

0. 部署

部署	passed	部署
8/9 部署 ut-20260807-110322	6,019	部署 failed 3,006 / error 904 / ignored 2,106 / retrieable 3
8/8 部署 ut-20260808-manifest-remaining部署	6,080	failed 3,095 / error 810 / ignored 2,170 / retrieable 5
dataset 8/20 部署	4,456 + 1,624 pending	1,624 部署 pending

1. 部署部署

1.1 部署

部署	部署	部署 (passed)	部署
A. 部署部署	2,122	34.9%	vllm 0.13.0 部署 torch 2.5.1 / triton 3.5.0 部署部署
B. 部署部署/部署	1,301	21.4%	部署/部署部署
C. timeout 部署executor 部署	1,787	29.4%	watchdog SIGKILL/JUnit 部署部署
D. 部署部署/executor 部署	870	14.3%	部署 214部署 17部署 5

1.2 部署部署A 部署2,122 部署

部署	部署	部署	部署
marlin 部署gptq_marlin_gemm/repack/moe_wna16/marlin_int4_fp8 + opcheck	841	部署 CUDA arch 部署 sm52部署marlin 部署 8.0+PTX部署	easy
triton_key 部署	519	vllm 0.13.0 部署 triton.compiler.compiler.triton_key部署 triton 3.5.0 部署	medium

cat_cuda 问题 Float8_e4m3fn	225	torch 2.5.1 中 cat_cuda 问题 FP8 中 cat	medium
engine 问题	181	deep_gemm/triton/FP8 问题 engine 中	medium
deep_gemm 问题	133	vllm 0.13.0 问题 deep_gemm问题/中	easy
torch 中 float8_e8m0fnu	80	torch ≥2.7 问题2.5.1 问题	difficult
triton 问题/中	69	Cannot find a working triton installation	easy
flash_attn head_size 中	64	head_size should be a multiple of 16	medium
opcheck 问题	64	marlin 问题 opcheck test_schema 中	easy
cuDNN 中	8	CUDNN_STATUS_NOT_INITIALIZED!mamba causal_conv1d	medium
inductor 问题 torch≥2.9	2	use_inductor_graph_partition 问题	easy

1.2.1 marlin 问题

```
1 问题 NotImplementedError: Could not run '_C::gptq_marlin_gemm' 中479+ repack中292+ opcheck中64≈ 841 中
2 问题 nm -D vllm/_C.abi3.so | grep -ic marlin → 0 中 marlin 中
3 问题 CMakeCache.txt 中 CMAKE_CUDA_ARCHITECTURES:STRING=52 中sm_52中marlin 问题 MARLIN_ARCHS = 8.0+PTX 中 CUDA_ARCHS → 问题
marlin 0 中
4 中 H20 中nvidia-smi 中 H20 compute_cap = 9.0中sm_90中 marlin 问题 → 问题
5 中 _moe_C.abi3.so 8/7 中 moe marlin 问题 4 中 → 问题
中 问题 arch 问题 = TORCH_CUDA_ARCH_LIST="9.0" 问题 841 中
```

1.2.2 triton_key 问题

```
1 问题 ImportError: cannot import name 'triton_key' from 'triton.compiler.compiler' 中495 + 24 中
2 问题 from triton.compiler.compiler import triton_key → 中 ImportError
3 问题 triton 3.5.0python3.12
中 triton 中 vllm 0.13.0 问题 triton 中 patch 中
```

1.2.3 torch 2.5.1 问题FP8 问题

- cat_cuda not implemented for 'Float8_e4m3fn' 中225 中torch 2.5.1 cat 问题 FP8问题 test_batched_moe.py(192)
- module 'torch' has no attribute 'float8_e8m0fnu' 中80 中E8M0 中 torch 2.7+ 中vllm 0.13.0 问题 → 问题 vllm 0.13.0 问题 torch 2.5.1
- 问题 305 中torch 2.5.1 中 vllm 0.13.0问题FP8 中 H20 中

1.3 问题B 中~1,314 中—— 问题

中	failed	error	中
HF 问题	378	529	907
HF 问题/中	39	98	137
中 repo ID!ValidationError	253	7	260
Harmony vocab 问题	7	3	10

TOP deepseek-ai/DeepSeek-R1 (48) · meta-llama/Meta-Llama-3-8B-Instruct (46) · meta-llama/Meta-Llama-3-8B (31) · microsoft/Phi-3.5-vision-instruct (24) · Qwen-VL · GLM-4.1V 29 meta-llama gated repo token

1.4 timeout C 1,787

JUnit XML unparseableSIGKILL mid-flush	1,038	watchdog XML
JUnit XML missing	488	XML
JUnit XML testcase	229	
timeout	32	pytest-timeout

test_detokenize.py (902) · test_attention.py(135) · test_chat_utils.py(41) · test_config.py(38) · test_spec_decode.py(34) executor watchdog bifrost 180s + timeout

detokenize 902 triton/FP8 A — \$4

1.5 D 870

	214	/ —
pytest skipped	246	
ignored	120	error_message —
	17	hybrid_lb_dp/internal_lb_dp
server/engine	168	A engine 181
retriable_error	5	bug 3 + bifrost 2 —
TypeError/ValueError/KeyError	~101	—

1.6

test_marlin_gemm.py	605	marlin
test_block_fp8.py	391+	triton_key + deep_gemm + FP8
test_moe.py	316	marlin_moe + FP8
test_batched_moe.py	288	cat_cuda Float8 + triton_key
test_initialization.py	158	engine
test_grouped_topk.py	96	triton_key
test_flash_attn.py	68	head_size

2. 2.5.1_ut_verify 30 commit

2.1 13 commit

Commit	日期	描述	影响
17190b075	06-26	PyTorch 2.5.1 更新 requirements/CMakeLists	无影响
d343dc8e0	06-29	编译 torch_compat.py	无影响
bf867df43	06-29	MemPool.snapshot 增加 stub	AttributeError: MemPool snapshot
284316193	06-24	torch._dynamo.config.recompile_limit 增加	torch>=2.6 无影响
04cd1dffb	05-28	list[torch.Tensor] -> List[torch.Tensor]	infer_schema 无影响
15565df57	05-29	DeepSeek torch_compile dynamic_arg_dims 增加	compile 无影响
f4f1077c9	07-28	Response API inline_call 增加 4 个 + enforce-eager	InternalTorchDynamoError
73810b8ff / 480f106b1 / 0969c54a1 / 3bf7e2f08 / 755a5000f	06-29~07-02	支持 meta-llama/Hermes 模型 + LoRA 推理	HF gated 无影响
e0b23b56c	08-03	run_collect.sh 增加	无影响

2.2 17 commit vllm 更新

Attention 支持 PrefixLM/FlexAttention/mm_prefix · DeepEP/DeepGEMM workspace 支持 · CPU/ROCm/XPU 支持 · Jais2 支持 · CI flaky 修复 · ApplyRotaryEmb CustomOp 支持

2.3 更新

更新项	说明
MemPool.snapshot / recompile_limit / inline_call / list[torch.Tensor] / meta-llama	支持 patch 更新
marlin 支持 841	支持 —— arch 支持
triton_key 支持 519	支持 —— triton 支持
cat_cuda Float8/ float8_e8m0fnu/80	支持 —— torch 2.5.1 支持

支持 torch API 支持 B 支持 marlin/triton/FP8 支持 —— 支持

3. 支持

- 支持 arch 支持 _C.abi3.so 支持 sm52 支持 marlin 支持 —— 支持 torch 支持 841 支持
- 支持 triton 支持 triton 3.5.0 支持 vllm 0.13.0 支持

- 3. HF 29 ~1,300 gated model_replacement.py
- 4. executor timeout 1,787 detokenize 902vs executor
- 5. 17 —
- 6. retrieable_error bug3 bash -c — apmm
- 7. GPU1 Xid31 exclude_gpus=[1] 8 cuDNN

4.

	214	vs vllm bug vs FP8
ignored	120	error_message
detokenize timeout	~200-300	
engine init	~50	
	~101	
entryptpoint	~6	
	~690-790	passed 11-13%

5.

26,875/32,955 = 81.5% passed 6,080 2,12234.9%marlin arch + triton + torch 2.5.1 FP8

easy ~1,04349%· medium ~550 · difficult ~800 1,301 timeout 1,787

torch —

torch 2.6+/2.7+ ① vllm 0.13.0 torch 2.7+ APIfloat8_e8m0fnu 80 ② torch 2.5.1 FP8 cat_cuda 225 FP8 H20

③ vllm main torch 2.11.0 2.5.1 ④ triton

④ marlin 841 ② 1,301 + timeout 1,787 + 5 ≈ 3,093 torch ③ 2.5.1

P0	TORCH_CUDA_ARCH_LIST="9.0" vllm marlin	+841
P0	vllm 0.13.0 triton patch triton_key	+519
P1	HF gated	+~1,300
P1	executor timeout	+~1,500

P2	torch 2.6/2.7 FP8cat_cuda/float8_e8m0fnu	+~305
P2	~690-790	

vllm 0.13.0 + torch 2.5.1 H20 1/3 torch 2.5.1 FP8 2.7 API FP8 torch 2.6+vllm marlin

runs/ut-20260808-manifest-remaining/manifest.json32,955 ut_logs.db error_message + /easy= medium= patch/ difficult= summary/non-passed 2026-08-22