

2026-06-08-2026-06-12

- 2026-06-08-2026-06-12
- 本周单元测试工作产出
- 待办项 (2026.6.22-2026.6.26)
- 本周工作明细
 - 单元测试
 - ut workflow执行模式讨论
 - hermes workflow
 - CPU性能对比测试
 - CPU规格对比
 - PCIe拓扑比较

本周单元测试工作产出

- 单元测试
 - ut workflow新增hermes运行模式并完成调试
 - 使得用户可以直接在飞书控制ut workflow的运行/获取运行状态，而不是仅仅被动获取运行结果
 - 基于ut workflow已经拉起剩余的单元测试
- CPU性能对比
 - 完成CPU规格对比，H100暂无可用于对比测试的CPU，只有H200可有不同规格CPU用于对比
 - 两款CPU核心参数一致（核数，主频和内存空间），区别是寻址能力和PCIe拓扑
 - 两台H200机器上已经完成vllm 0.13.0镜像上传和Minimax-M2.7下载

待办项 (2026.6.22-2026.6.26)

- 输出H200上性能测试报告，对比不同CPU带来影响
- 导出新的单元测试报告至某所

本周工作明细

单元测试

引入hermes运行ut workflow的设计文档参考附件 2026-06-18-hermes-workflow-dual-channel-design.md（可单独提供）

ut workflow执行模式讨论

维度	Hermes 运行	OpenCode 运行	Claude Code 运行
长期后台运行	最适合	不理想	不理想
飞书收信	已确认可支持	需要额外实现	需要额外实现
飞书通知	适合	可做	可做
OTP 获取	可由 Hermes 直接收飞书回复	通常要用户回到聊天窗口	通常要用户回到聊天窗口
bastion daemon 托管	适合做成 Runner 能力	容易依赖当前会话	容易依赖当前会话
断线恢复	适合自动化	会话型，不稳定	会话型，不稳定
Workflow 状态机	适合	可以做但不自然	可以做但不自然
代码修改/调试	不一定是主职责	很适合	很适合
人工架构讨论	不适合	很适合	很适合
是否适合作为最终 Runner	是	否，适合启动/维护	否，适合启动/维护

hermes workflow

相同点：Stage 2-5 执行逻辑

两者都是 Supervisor 模式：按 Stage 顺序加载 Worker SKILL.md, Agent 执行。这部分完全一致。

Stage 2: 加载 batch-selector/SKILL.md → Agent 选批次
Stage 3: 加载 unit-test-executor/SKILL.md → Agent 执行 pytest
Stage 4: 加载 failure-handler/SKILL.md → Agent 分析修复
Stage 5: 加载 manifest-updater/SKILL.md → Agent 更新状态

通知规则也一致：progress / alert(>0.5) / milestone / paused / complete.

不同点

维度	ut/workflow	hermes_workflow
触发	终端关键词	飞书关键词 / Hermes CLI
初始化	Step 0 交互式问答 (test_list? manifest? resume?)	直接读 workflow.yaml (预配置好的)
Bastion	Step 1 检查 → 断了提示用户手动修	hermes_runner 工具箱自动管理 (心跳+OTP)
飞书	单向发通知	双向: 收 OTP + 收用户指令 + 发通知
用户交互	终端问答	飞书消息 (指令需匹配状态机)
暂停/恢复	没有一断了就停了	完整状态机: running/paused/waiting_otp/reconnecting/stopped/completed/failed
pending_config	没有	支持用户飞书改参数
工具模块	不依赖 hermes_runner.py	import hermes_runner 作为工具箱

CPU性能对比测试

CPU的主频、核数和内存都一样

GPU都是全互联

8558 有10个以太/IB网口, 使用的固件版本28.42.1000

8568Y+ 有11个以太/IB网口, 使用的固件版本28.41.1000

主干网卡使用Mellanox MT4129 (ConnectX-7 芯片)


CPU规格对比

对比维度	qb-prod-gpu2206	qb-prod-gpu809
CPU 处理器型号	INTEL(R) XEON(R) PLATINUM 8558	INTEL(R) XEON(R) PLATINUM 8568Y+
逻辑核心总数	192 (CPU 0-191)	192 (CPU 0-191)
单路核心推断	双路, 单 CPU 48 核 96 线程	双路, 单 CPU 48 核 96 线程
最高主频	4.0 GHz (4000 MHz)	4.0 GHz (4000 MHz)
最低主频	0.8 GHz (800 MHz)	0.8 GHz (800 MHz)
物理寻址能力	52 bits physical, 57 bits virtual	46 bits physical, 57 bits virtual
内存总大小	2.0 TiB	2.0 TiB
内存单条规格	64 GB DDR5 (Samsung)	64 GB DDR5 (Samsung)
内存带宽 (速率)	标称 5600 MT/s, 实际运行 4400 MT/s	标称 5600 MT/s, 实际运行 4400 MT/s
NUMA 节点总数	2 个 (Node 0 & Node 1)	2 个 (Node 0 & Node 1)
NUMA 0 核心分布	Core 0-47, 96-143	Core 0-47, 96-143
NUMA 1 核心分布	Core 48-95, 144-191	Core 48-95, 144-191

PCIe拓扑比较


8568Y+ 相比8558, 更有可能发生拥塞, 影响GpuRDMA输

8558



每一个PCIe Switch下挂载一个GPU和一个NIC

8568Y+



每一个PCIe Switch下挂载一个GPU和多个NIC